

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

# Uso de redes neuronales convolucionales para el reconocimiento de imágenes hiperespectrales

Semillero MAC: Marlon Algarra

Universidad Distrital Francisco José de Caldas

Junio 7 de 2019

# Contenido

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

**1** Preliminares

**2** Diseño

**3** Resultados del algoritmo

**4** Conclusiones

# Preliminares

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

## Imágenes hiperespectrales

Denotada como HSI, son imágenes que contienen información espacial y espectral. Son obtenidas con cámaras especiales. Computacionalmente se entienden como una matriz de tres dimensiones  $(x, y, \lambda)$  donde  $x$ ,  $y$  representan el tamaño y  $\lambda$  la cantidad de bandas contiguas que posee.

## Redes neuronales convolucionales

Denotada como CNN, son una clase de redes neuronales, cuyo funcionamiento trata de asemejarse a los procesos biológicos del cerebro. Son altamente efectivas para el reconocimiento y análisis de imágenes.

# Preliminares

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

## Folded-PCA

Es un algoritmo estadístico que usa el álgebra lineal para la reducción de dimensionalidad y la extracción de características de conjuntos de datos de alta dimensionalidad.

## Softmax regression

Conocida también como regresión logística multinomial, es la generalización para el uso de múltiples clases (en vez de la binaria) del algoritmo estadístico de regresión logística.

CNN-HSI

S-MAC

Preliminares

**Diseño**

Resultados del  
algoritmo

Conclusiones

## Objetivo propuesto

Mostrar un procedimiento de CNN de alta precisión, que sea capaz de clasificar los píxeles presentes en un conjunto HSI en varias clases

## Extracción de características espectrales

Se utiliza en este caso una CNN de una dimensión para la extracción de características espectrales  $(x, y, \lambda)$ , donde los vectores de entrada o 'inputs' son un conjunto de píxeles de  $5 \times 5 \times \lambda$

## Función de activación y función de pérdida

ReLU

$$f(n) = \max(0.01 \times n, n)$$

Loss

$$\text{loss}(m, w) = -\frac{1}{m} \sum_{i=1}^m o_i \log(z_i) + (1 - o_i) \log(1 - z_i) + \frac{\lambda'}{2m} \sum_{j=1}^W w_j^2$$

## Extracción de características espaciales

Se utiliza el método de Folded-PCA para reducir la dimensionalidad del conjunto para obtener  $(x, y, 3)$ . Con este nuevo conjunto de datos, se extraen vectores de  $R \times R \times 3$  para entrenar una CNN de dos dimensiones. Como función de activación se utiliza también ReLU y la función de pérdida es la misma. En ambas CNN se utilizó el algoritmo de gradiente adaptativo para los mínimos.

# Diseño

CNN-HSI

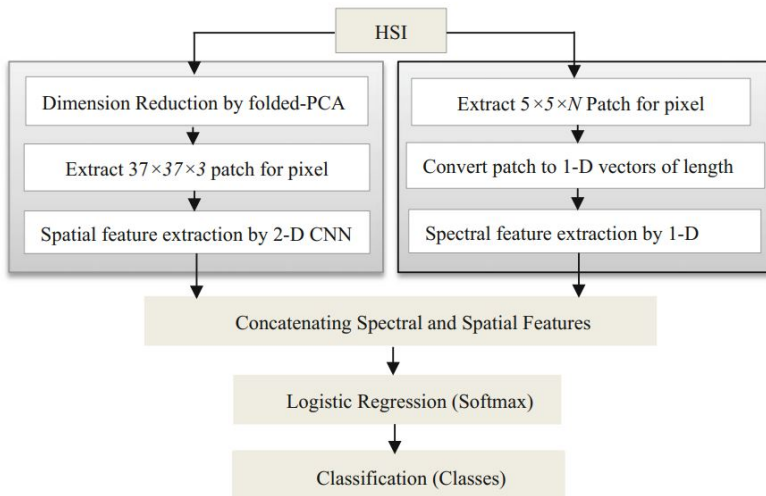
S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones





# Resultados

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

## Características de entrenamiento:

- Python v3.5
- Entorno Anaconda Navigator
- Tensorflow framework (Máquina de 64-bits)
- Procesador a 2.4 Ghz
- 8 Gb de ram

# Resultados (Datasets)

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

## Indian Pines

Conjunto de datos adquirido en 1992. Con características  $(145, 145, 224)$  con un rango de longitud de onda  $0.4\mu - 2.5\mu$  y una resolución espacial de 20 metros. Hay 10239 píxeles etiquetados que son cerca de la mitad de todos los píxeles y son 16 clases diferentes.

# Resultados(Indian Pines)

CNN-HSI


S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones



# Resultados(Indian Pines)

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

Parameters	Chen et al. [14]	Makantasis et al. [18]	Proposed
OA	97.78	98.63	98.87
AA	97.11	97.90	98.23
$K$	97.54	98.32	98.61

# Resultados (Datasets)

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

## University of Pavia

Conjunto de datos adquirido en 1988. Con características  $(610, 340, 103)$  con un rango de longitud de onda  $0.43\mu - 0.86\mu$  y una resolución espacial de 1.3 metros por pixel. Hay 42776 pixeles etiquetados de los 207400 que hay y son 9 clases diferentes.

# Resultados(University of Pavia)

CNN-HSI


S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones



# Resultados(University of Pavia)

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

Parameters	Chen et al. [14]	Makantasis et al. [18]	Proposed
OA	98.49	99.51	99.60
AA	97.75	98.99	99.12
$K$	98.05	99.20	99.42

# Conclusiones

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

El artículo logra mostrar un modelo de Deep Learning con mayor exactitud que anteriores resultados, mostrando así, que el entrenamiento por separado para extraer individualmente las características tanto espaciales como espectrales, resultó ser un método acertado para mejorar la exactitud de clasificación.



# Referencias

CNN-HSI

S-MAC

Preliminares

Diseño

Resultados del  
algoritmo

Conclusiones

- Kalita,S.,Biswas,M.: Improved Convolutional Neural Networks for Hyperspectral Image Classification (2019)
- [deeplearning.stanford.edu/tutorial/supervised/SoftmaxRegression](https://deeplearning.stanford.edu/tutorial/supervised/SoftmaxRegression)
- <https://www.sciencedirect.com/science/article/abs/pii/S0924271614000938>